

8.Comparació d'estimadors





Estadística
Grau en Matemàtiques

Josep A. Sanchez
Dept. Estadística i I.O.(UPC)



UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH

Propietats dels estimadors: Exactitud i Precisió



- Sigui W un estimador del paràmetre θ
- Es defineix com a **biaix** de l'estimador: $B_{\theta}(W) = E(W) - \theta$
- El biaix pot ser positiu (sobrestimació) o negatiu (infraestimació)
- Els estimadors W amb $B_{\theta}(W) = 0$ són estimadors no esbiaixats (*unbiased*)

- **Error Quadràtic Mig** d'un estimador (*Mean Square Error, MSE*)

$$MSE_{\theta}(W) = E_{\theta}[(W - \theta)^2]$$

- Es una mesura de la distància entre l'estimador i el valor del paràmetre que es vol estimar

$$\begin{aligned} E_{\theta}[(W - \theta)^2] &= E_{\theta}[(W - E_{\theta}(W) + E_{\theta}(W) - \theta)^2] = \\ E_{\theta}[(W - E_{\theta}(W))^2] - 2E_{\theta}[(W - E_{\theta}(W))(E_{\theta}(W) - \theta)] &+ E_{\theta}[(E_{\theta}(W) - \theta)^2] \\ &= E_{\theta}[(W - E_{\theta}(W))^2] + (E_{\theta}(W) - \theta)^2 = V(W) + B_{\theta}(W)^2 \end{aligned}$$

- W^* és un **millor estimador sense biaix** o **estimador sense biaix uniformement de mínima variància** de $\tau(\theta)$ si:
 - $E(W^*) = \tau(\theta) \quad \forall \theta \in \Theta$
 - Si W és un altre estimador sense biaix de $\tau(\theta)$ llavors,
 $V(W^*) \leq V(W)$
- En anglès es coneixen com *UMVUE (Uniform Minimum Variance Unbiased Estimator)*

- Sigui X una variable aleatòria amb densitat $f(x|\theta)$
- Es considera que el suport de θ és un interval obert a la recta real
- Definició: **Informació de Fisher de θ continguda en la variable X :**

$$I_X(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \log f_X(X|\theta) \right)^2 \right]$$

- Sigui X_1, \dots, X_n una m.a.s. amb

$$L(\theta; \underline{X}) = f(\underline{X}|\theta) = \prod_{i=1}^n f(x_i|\theta)$$

- La **informació de Fisher** continguda en la mostra pel paràmetre θ es defineix en base a la densitat conjunta:

$$I_{\underline{X}}(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \log f_{\underline{X}}(\underline{X}|\theta) \right)^2 \right]$$

Lema 1

- Sigui X_1, \dots, X_n una m.a.s, llavors,

$$l_{\tilde{X}}(\theta) = n l_X(\theta)$$

- **Demostració:**

$$\frac{\partial}{\partial \theta} \log f(\tilde{X}|\theta) = \frac{\partial}{\partial \theta} \log \prod_{i=1}^n f(x_i|\theta) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(x_i|\theta)$$

Llavors,

$$\begin{aligned} l_{\tilde{X}}(\theta) &= E \left[\left(\frac{\partial}{\partial \theta} \log f_{\tilde{X}}(\tilde{X}|\theta) \right)^2 \right] = E \left[\left(\sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(x_i|\theta) \right)^2 \right] = \\ &= E \left[\sum_{i=1}^n \left(\frac{\partial}{\partial \theta} \log f(x_i|\theta) \right)^2 + \sum_{i \neq j} \left(\frac{\partial}{\partial \theta} \log f(x_i|\theta) \frac{\partial}{\partial \theta} \log f(x_j|\theta) \right) \right] = \\ &= n E \left[\left(\frac{\partial}{\partial \theta} \log f(x|\theta) \right)^2 \right] + \sum_{i \neq j} E \left[\frac{\partial}{\partial \theta} \log f(x_i|\theta) \right] E \left[\frac{\partial}{\partial \theta} \log f(x_j|\theta) \right] \end{aligned}$$

- **Demostració** (cont.) Només queda demostra que

$$E \left[\frac{\partial}{\partial \theta} \log f(x_i | \theta) \right] = 0 \text{ i haurem demostrat que } l_{\tilde{X}}(\theta) = n l_X(\theta)$$

$$\begin{aligned} E \left[\frac{\partial}{\partial \theta} \log f(x_i | \theta) \right] &= \int \left(\frac{\partial}{\partial \theta} \log f(x_i | \theta) \right) f(x_i | \theta) dx_i = \int \left(\frac{\frac{\partial}{\partial \theta} f(x_i | \theta)}{f(x_i | \theta)} \right) f(x_i | \theta) dx_i = \\ &= \int \left(\frac{\partial}{\partial \theta} f(x_i | \theta) \right) dx_i = \frac{\partial}{\partial \theta} \int f(x_i | \theta) dx_i = \frac{\partial}{\partial \theta} 1 = 0 \end{aligned}$$

- Necessitem la condició de regularitat que contempla que la derivada respecte el paràmetre i la integral de la variable conmuten:
- Hipòtesi H1: $\frac{\partial}{\partial \theta} \int f(x | \theta) dx_i = \int \frac{\partial}{\partial \theta} f(x | \theta) dx$

- La funció $S(\theta; \underline{X}) = \frac{\partial}{\partial \theta} \log f(\underline{X}|\theta)$ es denomina **funció Score**
- Per buscar els punts singulars, busquem els valors de θ on la funció de Score s'anul·la.
- En l'anterior demostració hem vist que $E(S(\theta; \underline{X})) = 0$
- D'altra banda, la variància d'aquesta funció és la informació de Fisher:

$$I_{\underline{X}}(\theta) = E(S(\theta; \underline{X})^2) = V(S(\theta; \underline{X}))$$

- La informació de Fisher mesura la curvatura de la funció $\log L(\theta; \underline{X})$: els models amb molta curvatura tenen molta informació (més precisió en l'estimació)

Sota la hipòtesis (H2): $\frac{\partial^2}{\partial \theta^2} \int f(x|\theta) dx_i = \int \frac{\partial^2}{\partial \theta^2} f(x|\theta) dx$

Es pot obtenir una expressió alternativa per a la informació de Fisher pel paràmetre θ :

- Continguda a la variable x :

$$I_X(\theta) = E \left[-\frac{\partial^2}{\partial \theta^2} \log f(X|\theta) \right]$$

• Demostració:

$$\begin{aligned}
 I_X(\theta) + E \left[\frac{\partial^2}{\partial \theta^2} \log(f(x|\theta)) \right] &= \\
 &= \int \left[\left(\frac{\partial}{\partial \theta} \log(f(x|\theta)) \right)^2 + \left(\frac{\partial^2}{\partial \theta^2} \log(f(x|\theta)) \right) \right] f(x|\theta) dx \\
 &= \int \left(\frac{\partial}{\partial \theta} \log(f(x|\theta)) \right) \frac{\frac{\partial}{\partial \theta} f(x|\theta)}{f(x|\theta)} f(x|\theta) dx + \int \left(\frac{\partial^2}{\partial \theta^2} \log(f(x|\theta)) \right) f(x|\theta) dx \\
 &= \int \frac{\partial}{\partial \theta} \log(f(x|\theta)) \frac{\partial}{\partial \theta} f(x|\theta) dx + \int \left(\frac{\partial^2}{\partial \theta^2} \log(f(x|\theta)) \right) f(x|\theta) dx \\
 &= \int \frac{\partial}{\partial \theta} \left[\left(\frac{\partial}{\partial \theta} \log(f(x|\theta)) \right) f(x|\theta) \right] dx = \int \frac{\partial}{\partial \theta} \left[\left(\frac{\frac{\partial}{\partial \theta} f(x|\theta)}{f(x|\theta)} \right) f(x|\theta) \right] dx \\
 &= \int \frac{\partial}{\partial \theta} \left[\frac{\partial}{\partial \theta} f(x|\theta) \right] dx = \frac{\partial^2}{\partial \theta^2} \int f(x|\theta) dx = 0
 \end{aligned}$$

- Generalització: Informació pel paràmetre continguda en una mostra \underline{X} :

$$I_{\underline{X}}(\theta) = E \left[-\frac{\partial^2}{\partial \theta^2} \log f(\underline{X}|\theta) \right] = E \left[-\frac{\partial^2}{\partial \theta^2} \log L(\theta; \underline{X}) \right]$$

Teorema:

Sigui X_1, \dots, X_n m.a.s amb funció de densitat conjunta $f(\underline{X}|\theta)$ i sigui $W(\underline{X})$ un estimador sense biaix de $\tau(\theta)$ amb

- $V(W(\underline{X})) < \infty$
- $\frac{\partial}{\partial \theta} E[W(\underline{X})] = \int \frac{\partial}{\partial \theta} W(\underline{X}) f(\underline{X}|\theta) d\mathbf{x}$

Llavors,

$$V(W(\underline{X})) \geq \frac{\left(\frac{d}{d\theta} \tau(\theta)\right)^2}{E_{\theta} \left[\left(\frac{\partial}{\partial \theta} \log f(\underline{X}|\theta)\right)^2 \right]} = \frac{\tau'(\theta)^2}{I_{\underline{X}}(\theta)}$$

Desigualtat de Cramer-Rao

Demostració: (Desigualtat de Cauchy-Schwartz: $(x'y) \leq \|x\|^2\|y\|^2$)

Estadísticament,

$$\text{Cov}(X, Y)^2 \leq V(X)V(Y) \Rightarrow V(X) \geq \frac{\text{Cov}(X, Y)^2}{V(Y)}$$

Considerem $X \equiv W(\underline{X})$ i $Y \equiv \frac{\partial}{\partial \theta} \log(f(\underline{X}|\theta))$

Notem que

$$\begin{aligned} \frac{d}{d\theta} E(W(X)) &= \int W(x) \frac{\partial}{\partial \theta} f(x|\theta) dx = E \left(W(X) \frac{\frac{\partial}{\partial \theta} f(X|\theta)}{f(X|\theta)} \right) \\ &= E \left(W(X) \frac{\partial}{\partial \theta} \log(f(X|\theta)) \right) \end{aligned}$$

Aquesta expressió correspon a la covariància entre les dues variables (Def: $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$), ja que

$$E \left(\frac{\partial}{\partial \theta} \log(f(X|\theta)) \right) = \int \frac{\frac{\partial}{\partial \theta} f(x|\theta)}{f(X|\theta)} f(X|\theta) dx = \frac{\partial}{\partial \theta} \int f(x|\theta) dx = 0$$

Demostració(cont.):

$$\text{Cov} \left(W(X), \frac{\partial}{\partial \theta} \log(f(X|\theta)) \right) = E \left(W(X) \frac{\partial}{\partial \theta} \log(f(X|\theta)) \right) = \frac{d}{d\theta} E(W(X))$$


També,

$$V \left(\frac{\partial}{\partial \theta} \log(f(X|\theta)) \right) = E \left(\left(\frac{\partial}{\partial \theta} \log(f(X|\theta)) \right)^2 \right) \quad \text{ja que} \quad E \left(\frac{\partial}{\partial \theta} \log(f(X|\theta)) \right) = 0$$

Per tant,

$$V(W(X)) \geq \frac{\left(\frac{d}{d\theta} E(W(X)) \right)^2}{E_{\theta} \left[\left(\frac{\partial}{\partial \theta} \log f(X|\theta) \right)^2 \right]} = \frac{\tau'(\theta)^2}{I_X(\theta)}$$

Interpretació de la Informació de Fisher



- En moltes situacions $\tau(\theta) = \theta$ i la cota de Cramer-Rao correspon a l'invers de la Informació de Fisher:

$$V(W(X)) \geq \frac{1}{I_X(\theta)} = \frac{1}{nI_X(\theta)}$$

- Si un estimador sense biaix té una variància igual a la cota de Cramer-Rao, llavors és UMVUE
- Totes les distribucions de la família exponencial compleixen les condicions del teorema de Cramer-Rao
- Un estimador sense biaix que assoleix la cota de Cramer-Rao s'anomena **eficient**
- Tot estimador eficient és UMVUE. El recíproc no té perquè ser cert.

- La informació de Fisher pels paràmetres θ i $\tau(\theta)$ estan relacionades:

$$\begin{aligned} I_n(\theta) &= E \left(\left(\frac{\partial l}{\partial \theta} \right)^2 \right) = E \left(\left(\frac{\partial l}{\partial \tau} \frac{\partial \tau}{\partial \theta} \right)^2 \right) = \\ &= \tau'(\theta)^2 E \left(\left(\frac{\partial l}{\partial \tau} \right)^2 \right) = \tau'(\theta)^2 I_n(\tau(\theta)) \end{aligned}$$

Per tant,

$$I_n(\tau(\theta)) = \frac{I_n(\theta)}{\tau'(\theta)^2}$$

Assoliment de la Cota de Cramer-Rao

Sigui X_1, \dots, X_n una m.a.s. amb densitat $f(x|\theta)$, tal que $f(x|\theta)$ satisfà les condicions del teorema de Cramer-Rao.

Sigui $L(\theta|X) = \prod_{i=1}^n f(x_i|\theta)$ la funció de versemblança i sigui $W(X)$ un estimador sense biaix de $\tau(\theta)$.

Llavors $W(X)$ assoleix la cota de Cramer-Rao si i només si,

$$a(\theta)(W(X) - \tau(\theta)) = \frac{\partial}{\partial \theta} \log(L(\theta|X))$$

per certa funció $a(\theta)$